

Notebook export: analiza_opisowa_danych.ipynb

Cell 1 [markdown]

```
# Analiza Opisowa Danych
## Adult Census Income Dataset
### Analiza porównawcza dochodów kobiet i mężczyzn

**Twórca:** Mateusz Gawłowski 264463
**Przedmiot:** Metody planowania i analizy eksperymentów
**Data oddania:** 02.04.2026
```

Cell 2 [markdown]

```
## 1. Charakterystyka zbioru danych
```

Dane pochodzą z **UCI Machine Learning Repository** (*Adult Census Income*, Dua & Graff, 2019). Zbiór zawiera wyniki spisu ludności USA z 1994 roku i jest powszechnie stosowany w badaniach nad nierównościami dochodowymi.

```
| Zmienna | Typ | Opis |
|---|---|---|
| `age` | ilościowa | Wiek w latach |
| `education_num` | ilościowa | Liczba lat edukacji (1–16) |
| `hours_per_week` | ilościowa | Tygodniowy czas pracy |
| `capital_gain/loss` | ilościowa | Zyski/straty kapitałowe (USD) |
| `sex` | jakościowa | Płeć – **zmienna grupująca** |
| `income` | jakościowa | Dochód: `<=50K` lub `>50K` USD/rok |
| `workclass` | jakościowa | Sektor zatrudnienia |
| `occupation` | jakościowa | Zawód |
```

Zmienna grupująca: `sex` — umożliwia porównanie struktury dochodów kobiet i mężczyzn.

Cell 3 [markdown]

```
## 2. Narzędzia
```

Analizę przeprowadzono w **Python 3** z wykorzystaniem:

- `pandas` — wczytanie i transformacja danych
- `numpy` — obliczenia numeryczne
- `matplotlib`, `seaborn` — wizualizacje
- `scipy.stats` — test chi-kwadrat Pearsona

Cell 4 [code]

```
import pandas as pd
import numpy as np
import matplotlib.pyplot as plt
import seaborn as sns
from scipy import stats
import warnings
warnings.filterwarnings('ignore')
```

```
# Ustawienia wizualne
```

```
plt.rcParams.update({
'font.family': 'DejaVu Sans',
'font.size': 11,
'axes.titlesize': 12,
'axes.labelsize': 11,
'figure.dpi': 120,
})
sns.set_style('whitegrid')
```

```
PALETTE = {'Male': '#2563EB', 'Female': '#DB2777'}
print('Biblioteki za■adowane.')
[outputs]
Biblioteki za■adowane.
```

Cell 5 [markdown]

```
## 3. Wczytanie i przygotowanie danych
```

Cell 6 [code]

```
cols = ['age', 'workclass', 'fnlwgt', 'education', 'education_num',
'marital_status', 'occupation', 'relationship', 'race', 'sex',
'capital_gain', 'capital_loss', 'hours_per_week',
'native_country', 'income']

url = ('https://archive.ics.uci.edu/ml/machine-learning-databases/'
'adult/adult.data')

try:
df = pd.read_csv(url, header=None, names=cols,
na_values='?', skipinitialspace=True)
print(f'Dane wczytane z UCI: {len(df):,} wierszy')
except Exception:
print('Brak po■■czenia z UCI — generowanie danych syntetycznych...')
rng = np.random.default_rng(42)
n = 32561
age = rng.integers(17, 90, n)
sex = rng.choice(['Male', 'Female'], n, p=[0.67, 0.33])
ednum = rng.integers(1, 17, n)
hpw = rng.integers(1, 99, n)
cap_gain = np.where(rng.random(n) < 0.08, rng.integers(1, 99999, n), 0)
cap_loss = np.where(rng.random(n) < 0.05, rng.integers(1, 4356, n), 0)
p_inc = np.clip(
0.18 + 0.025 * (ednum - 9) + 0.003 * (age - 38)
+ np.where(sex == 'Male', 0.08, -0.04), 0.03, 0.95)
income = np.where(rng.random(n) < p_inc, '>50K', '<=50K')
wc_p = np.array([0.69, 0.08, 0.03, 0.03, 0.06, 0.04, 0.01, 0.006])
wc_p /= wc_p.sum()
wc = rng.choice(['Private', 'Self-emp-not-inc', 'Self-emp-inc',
'Federal-gov', 'Local-gov', 'State-gov',
'Without-pay', 'Never-worked'], n, p=wc_p)
occ = rng.choice(['Tech-support', 'Craft-repair', 'Other-service',
'Sales', 'Exec-managerial', 'Prof-specialty',
```

```

'Handlers-cleaners','Machine-op-inspct',
'Adm-clerical','Farming-fishing',
'Transport-moving','Priv-house-serv',
'Protective-serv','Armed-Forces'], n)
edu = rng.choice(['Bachelors','Some-college','11th','HS-grad',
'Prof-school','Assoc-acdm','Assoc-voc',
'9th','7th-8th','12th','Masters',
'1st-4th','10th','Doctorate','5th-6th','Preschool'], n)
ms = rng.choice(['Married-civ-spouse','Divorced','Never-married',
'Separated','Widowed','Married-spouse-absent',
'Married-AF-spouse'], n,
p=[0.46, 0.13, 0.33, 0.03, 0.04, 0.005, 0.005])
df = pd.DataFrame({'age': age, 'workclass': wc,
'education': edu, 'education_num': ednum,
'marital_status': ms, 'occupation': occ,
'sex': sex, 'capital_gain': cap_gain,
'capital_loss': cap_loss,
'hours_per_week': hpw, 'income': income})

```

```

# Czyszczenie danych
df.dropna(inplace=True)
df['sex'] = df['sex'].str.strip()
df['income'] = df['income'].str.strip()
df['income_bin'] = (df['income'] == '>50K').astype(int)

```

```

print(f'Po czyszczeniu: {len(df):,} wierszy, {df.shape[1]} kolumn')
print(f" Mężczyźni: {(df['sex']=='Male').sum():,}")
print(f" Kobiety: {(df['sex']=='Female').sum():,}")
df.head()

```

[outputs]

Dane wczytane z UCI: 32,561 wierszy

Po czyszczeniu: 32,561 wierszy, 16 kolumn

Mężczyźni: 21,790

Kobiety: 10,771

```

age      workclass  fnlwgt  education  education_num \
0  39      State-gov  77516  Bachelors      13
1  50  Self-emp-not-inc  83311  Bachelors      13
2  38      Private  215646   HS-grad        9
3  53      Private  234721   11th          7
4  28      Private  338409  Bachelors      13

```

```

marital_status  occupation  relationship  race  sex \
0  Never-married  Adm-clerical  Not-in-family  White  Male
1  Married-civ-spouse  Exec-managerial  Husband  White  Male
2      Divorced  Handlers-cleaners  Not-in-family  White  Male
3  Married-civ-spouse  Handlers-cleaners  Husband  Black  Male
4  Married-civ-spouse  Prof-specialty  Wife  Black  Female

```

```

capital_gain  capital_loss  hours_per_week  native_country  income \
0      2174          0          40  United-States  <=50K

```

1	0	0	13 United-States <=50K
2	0	0	40 United-States <=50K
3	0	0	40 United-States <=50K
4	0	0	40 Cuba <=50K

income_bin

0	0
1	0
2	0
3	0
4	0

Cell 7 [markdown]

4. Statystyki opisowe

Cell 8 [code]

```
num_vars = ['age', 'education_num', 'hours_per_week', 'capital_gain', 'capital_loss']

desc = df[num_vars].describe().T
desc['skewness'] = df[num_vars].skew()
desc['kurtosis'] = df[num_vars].kurt()
desc.columns = ['n', 'średnia', 'std', 'min', 'Q1', 'mediana', 'Q3', 'max', 'skoskośność', 'kurtoza']
desc.index = ['Wiek', 'Lata edukacji', 'Godz./tydzień', 'Zysk kapital.', 'Strata kapital.']
```

```
print('=== Statystyki opisowe zmiennych ilościowych ===')
desc.round(2)
```

[outputs]

```
=== Statystyki opisowe zmiennych ilościowych ===
n  średnia  std  min  Q1  mediana  Q3  \
Wiek      32561.0  38.58  13.64  17.0  28.0   37.0  48.0
Lata edukacji  32561.0  10.08   2.57   1.0   9.0  10.0  12.0
Godz./tydzień  32561.0  40.44  12.35   1.0  40.0  40.0  45.0
Zysk kapital.  32561.0 1077.65 7385.29   0.0   0.0   0.0   0.0
Strata kapital. 32561.0   87.30  402.96   0.0   0.0   0.0   0.0
```

max skoskośność kurtoza

Wiek	90.0	0.56	-0.17
Lata edukacji	16.0	-0.31	0.62
Godz./tydzień	99.0	0.23	2.92
Zysk kapital.	99999.0	11.95	154.80
Strata kapital.	4356.0	4.59	20.38

Cell 9 [code]

```
print('=== Statystyki według płci ===')
grp = df.groupby('sex')[['age', 'education_num', 'hours_per_week']].agg(
    ['mean', 'median', 'std']
).round(2)
grp.columns = ['_'.join(c) for c in grp.columns]
grp
```

[outputs]

```
=== Statystyki według płci ===
```

	age_mean	age_median	age_std	education_num_mean	\
sex					
Female	36.86	35.0	14.01	10.04	
Male	39.43	38.0	13.37	10.10	

	education_num_median	education_num_std	hours_per_week_mean	\
sex				
Female	10.0	2.38	36.41	
Male	10.0	2.66	42.43	

	hours_per_week_median	hours_per_week_std
sex		
Female	40.0	11.81
Male	40.0	12.12

Cell 10 [code]

```
# Odsetek dochodu >50K wedlug poci
p_income = df.groupby('sex')['income_bin'].agg(['mean', 'count'])
p_income.columns = ['odsetek >50K', 'n']
p_income['odsetek >50K'] = (p_income['odsetek >50K'] * 100).round(1)

print('=== Odsetek dochodów >50K USD/rok wedlug poci ===')
print(p_income)

# Test chi-kwadrat
ct = pd.crosstab(df['sex'], df['income'])
chi2, p_val, dof, _ = stats.chi2_contingency(ct)
print(f'\nTest chi-kwadrat (poci × dochód):')
print(f' chi2 = {chi2:.2f}, df = {dof}, p = {p_val:.2e}')
print(f' => Róznica jest {"ISTOTNA statystycznie" if p_val < 0.05 else "nieistotna"} (alpha = 0.05)')
[outputs]
=== Odsetek dochodów >50K USD/rok wedlug poci ===
odsetek >50K    n
sex
Female      10.9 10771
Male       30.6 21790

Test chi-kwadrat (poci × dochód):
chi2 = 1517.81, df = 1, p = 0.00e+00
=> Róznica jest ISTOTNA statystycznie (alpha = 0.05)
```

Cell 11 [markdown]

5. Wizualizacje

Cell 12 [markdown]

5.1 Rozkład wieku i poziomu wykształcenia wedlug poci

Cell 13 [code]

```
fig, axes = plt.subplots(1, 2, figsize=(13, 4.5))

# Histogram wieku
ax = axes[0]
```

```

for s, color in PALETTE.items():
    subset = df[df['sex'] == s][age]
    ax.hist(subset, bins=30, alpha=0.6, color=color, label=s, density=True)
    ax.set_xlabel('Wiek')
    ax.set_ylabel('Gęstość')
    ax.set_title('Rozkład wieku według płci')
    ax.legend()

# Violin wykształcenia
ax = axes[1]
sns.violinplot(data=df, x='sex', y='education_num',
               palette=PALETTE, order=['Male', 'Female'],
               inner='quartile', ax=ax, linewidth=0.8)
ax.set_xlabel('Płeć')
ax.set_ylabel('Poziom wykształcenia (lata)')
ax.set_title('Rozkład poziomu wykształcenia według płci')

plt.tight_layout()
plt.show()

print('Interpretacja:')
print(f" Wiek — mężczyźni: {df[df['sex']=='Male'][age].mean():.1f} lat, "
      f" kobiety: {df[df['sex']=='Female'][age].mean():.1f} lat")
print(f" Edukacja — mężczyźni: {df[df['sex']=='Male'][education_num].mean():.2f} lat, "
      f" kobiety: {df[df['sex']=='Female'][education_num].mean():.2f} lat")
[outputs]
<Figure size 1560x540 with 2 Axes>
Interpretacja:
Wiek — mężczyźni: 39.4 lat, kobiety: 36.9 lat
Edukacja — mężczyźni: 10.10 lat, kobiety: 10.04 lat

```

Cell 14 [markdown]

```

#### 5.2 Tygodniowy czas pracy i odsetek dochodów >50K według płci

```

Cell 15 [code]

```

fig, axes = plt.subplots(1, 2, figsize=(13, 4.5))

# Boxplot godzin pracy
ax = axes[0]
sns.boxplot(data=df, x='sex', y='hours_per_week', hue='income',
            palette={'<=50K': '#93C5FD', '>50K': '#1E3A5F'},
            order=['Male', 'Female'], ax=ax, width=0.5, linewidth=0.8,
            flierprops=dict(marker='o', markersize=2, alpha=0.3))
ax.set_xlabel('Płeć')
ax.set_ylabel('Godziny pracy / tydzień')
ax.set_title('Tygodniowy czas pracy wg płci i dochodu')
ax.legend(title='Dochód')

# Średni odsetek >50K
ax = axes[1]
colors_bar = [PALETTE[s] for s in p_income.index]

```

```

bars = ax.bar(p_income.index, p_income['odsetek >50K'],
color=colors_bar, edgecolor='white', width=0.5)
for bar, val in zip(bars, p_income['odsetek >50K']):
ax.text(bar.get_x() + bar.get_width()/2, bar.get_height() + 0.5,
f'{val:.1f}%', ha='center', va='bottom', fontweight='bold', fontsize=12)
ax.set_ylim(0, p_income['odsetek >50K'].max() * 1.25)
ax.set_ylabel('Odsetek osób z dochodem >50K [%]')
ax.set_title('Odsetek osób zarabiających >50K USD/rok\nwedług płeći')
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)

plt.tight_layout()
plt.show()

```

```

m_med = df[df['sex']=='Male']['hours_per_week'].median()
f_med = df[df['sex']=='Female']['hours_per_week'].median()
print(f'Mediana godzin pracy: mężczyźni = {m_med:.0f} h, kobiety = {f_med:.0f} h')

```

[outputs]

<Figure size 1560x540 with 2 Axes>

Mediana godzin pracy: mężczyźni = 40 h, kobiety = 40 h

Cell 16 [markdown]

5.3 Macierz korelacji

Cell 17 [code]

```

fig, ax = plt.subplots(figsize=(7, 5.5))

corr_vars = ['age', 'education_num', 'hours_per_week',
'capital_gain', 'capital_loss', 'income_bin']
corr_labels = ['Wiek', 'Lata edukacji', 'Godz./tyg.',
'Zysk kapital.', 'Strata kapital.', 'Dochód >50K']

corr = df[corr_vars].corr()
corr.index = corr_labels
corr.columns = corr_labels

mask = np.triu(np.ones_like(corr, dtype=bool))
sns.heatmap(corr, mask=mask, annot=True, fmt='.2f',
cmap='RdBu_r', center=0, ax=ax,
linewidths=0.5, cbar_kws={'shrink': 0.8},
annot_kws={'size': 10})
ax.set_title('Macierz korelacji zmiennych numerycznych')
plt.tight_layout()
plt.show()

```

[outputs]

<Figure size 840x660 with 2 Axes>

Cell 18 [markdown]

5.4 Zawody według odsetka dochodów >50K

Cell 19 [code]

```

if 'occupation' in df.columns:

```

```

occ_stat = (
df.groupby('occupation')['income_bin']
.agg(['mean', 'count'])
.query('count >= 200')
.sort_values('mean', ascending=True)
)
fig, ax = plt.subplots(figsize=(9, 4.5))
bars = ax.barh(occ_stat.index, occ_stat['mean'] * 100,
color='#1E3A5F', edgecolor='white')
for bar, val in zip(bars, occ_stat['mean'] * 100):
ax.text(bar.get_width() + 0.3, bar.get_y() + bar.get_height()/2,
f'{val:.1f}%', va='center', fontsize=9)
ax.set_xlabel('Odsetek osób z dochodem >50K [%]')
ax.set_title('Odsetek dochodów >50K według zawodu')
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
plt.tight_layout()
plt.show()
[outputs]
<Figure size 1080x540 with 1 Axes>

```

Cell 20 [markdown]

5.5 Analiza porównawcza — dochód według płci i wykształcenia

Cell 21 [code]

```

# Odsetek >50K wg płci i poziomu wykształcenia (pogrupowanego)
edu_bins = [0, 8, 10, 13, 16]
edu_labels = ['Podstawowe\n(1–8)', 'Średnie\n(9–10)', 'Wyższe I st.\n(11–13)', 'Wyższe II/III\n(14–16)']
df['edu_group'] = pd.cut(df['education_num'], bins=edu_bins, labels=edu_labels)

pivot = df.groupby(['edu_group', 'sex'])['income_bin'].mean().unstack() * 100

fig, ax = plt.subplots(figsize=(9, 4.5))
x = np.arange(len(pivot))
w = 0.35
b1 = ax.bar(x - w/2, pivot.get('Male', [0]*len(pivot)),
width=w, color=PALETTE['Male'], label='Mężczyźni', alpha=0.85)
b2 = ax.bar(x + w/2, pivot.get('Female', [0]*len(pivot)),
width=w, color=PALETTE['Female'], label='Kobiety', alpha=0.85)

ax.set_xticks(x)
ax.set_xticklabels(pivot.index)
ax.set_ylabel('Odsetek dochodów >50K [%]')
ax.set_title('Odsetek dochodów >50K według płci i poziomu wykształcenia')
ax.legend()
ax.spines['top'].set_visible(False)
ax.spines['right'].set_visible(False)
plt.tight_layout()
plt.show()

print('Odsetek dochodów >50K wg płci i wykształcenia [%]:')

```



```
print(pivot.round(1))
```

[outputs]

<Figure size 1080x540 with 1 Axes>

Odsetek dochodów >50K wg płci i wykształcenia [%]:

sex	Female	Male
edu_group		
Podstawowe\n(1–8)	1.7	7.5
Średnie\n(9–10)	6.8	22.8
Wyższe I st.\n(11–13)	18.2	45.3
Wyższe II/III\n(14–16)	38.0	70.9

Cell 22 [markdown]

6. Wnioski

6.1 Luka płacowa

Odsetek osób zarabiających powyżej 50 000 USD/rok jest ponad dwukrotnie wyższy wśród mężczyzn niż wśród kobiet. Test chi-kwadrat Pearsona potwierdza, że różnica ta jest ****wysoko istotna statystycznie**** ($p < 0,001$), co wyklucza przypadkowy charakter obserwacji.

6.2 Czas pracy

Mężczyźni pracują przeciętnie więcej godzin tygodniowo niż kobiety. W obu grupach osoby z dochodem >50K wykazują dłuższy czas pracy niż osoby z dochodem ≤50K. Dłuższy czas pracy częściowo tłumaczy wyższe zarobki mężczyzn, jednak nie jest jedynym czynnikiem.

6.3 Wykształcenie

Rozkłady poziomu edukacji są niemal identyczne dla kobiet i mężczyzn (podobne mediany i odchylenia standardowe), co sugeruje, że ****różnice edukacyjne nie są przyczyną**** obserwowanej luki płacowej. Co istotne, nawet przy tym samym poziomie wykształcenia odsetek kobiet zarabiających >50K jest niższy niż mężczyzn w każdej grupie edukacyjnej.

6.4 Predyktory dochodu

Najsilniejszymi korelatorami dochodu są:

- liczba lat edukacji ($r \approx 0,33$),
- wiek ($r \approx 0,24$),
- tygodniowy czas pracy ($r \approx 0,23$).

Typ zawodu ma kluczowe znaczenie — zarządzanie i specjalności osiągały najwyższy odsetek dochodów >50K.

6.5 Ograniczenia

Dane pochodzą z 1994 roku — wnioski odnoszą się wyłącznie do ówczesnego rynku pracy USA. Analiza korelacyjna nie wyznacza związków przyczynowych.

****Źródło:**** Dua, D. & Graff, C. (2019). **UCI Machine Learning Repository**. Irvine, CA: University of California.
<https://archive.ics.uci.edu/ml/datasets/adult>